

Pronosticando el físico

Aprendizaje automático para predecir el cambio del
cuerpo al perder peso

Pablo Ramón Guevara

24/07/2023

Hemos usado un modelo del cuerpo 3D y una red neuronal para predecir cómo cambia el cuerpo durante un régimen de pérdida de peso.

Hemos usado un modelo del cuerpo 3D y una red neuronal para predecir cómo cambia el cuerpo durante un régimen de pérdida de peso.

- Revisión de la literatura sobre modelar cuerpos humanos en 3D.
- Procesamiento y limpieza de los datos disponibles.
- Desarrollo e implementación de una red neuronal.

Representación del cuerpo en 3D

Revisión de la literatura

[962] *3D Human Body Models: Parametric and Generative Methods Review*

Nahuel Emiliano García D'Urso (Universidad de Alicante), Jorge Azorín-López (University of Alicante), Andres Fuster-Guillo (Universidad de Alicante) and Pablo Ramon Guevara (Universidad de Alicante).

The paper provides an overview of the current status of 3D human body model estimation, reconstruction, and generation in computer vision. The focus is on the commonly used parametric and generative methods and their applications in various fields, such as medicine, film, video games, and clothing. Parametric models use parameters to represent body shape and pose, and they are commonly used to reconstruct 3D human bodies. These models have different features, including those that focus on body deformations, shape, and pose optimization, and the separation of body shape into identity-specific and pose-dependent components. Generative methods, such as Variational Autoencoder and Generative Adversarial Networks, have been developed to generate 3D models of the human body by learning the data distribution. These advancements have improved the accuracy and stability of representing human body shapes and poses.

Presentada en la conferencia IWANN 2023.

Taxonomía de modelos

Basada en los tipos de entradas y salidas:

Entradas

- 2D (imágenes, vídeos...)
- 3D
- Modelos paramétricos

Salidas

- Espacio 2D
- Mallas 3D
- Vóxels 3D
- *NeRF*


Modelos paramétricos

Representar y generar modelos 3D basados en
parámetros ajustables.

Skinned Multi-Person Linear Model (SMPL)

Permite descomponer un cuerpo en:

- Malla de topología estática T
- 10 parámetros de forma β
- 72 parámetros de pose θ



Análisis de datos y preprocesamiento

Datos disponibles

- 80 pacientes
- 400 sesiones
- 200 escaneos 3D

Tipo	Fuente	Medidas (unidad)
Antropométrico	Cinta métrica flexible	<ul style="list-style-type: none"> • Muñeca (cm) • Cintura (cm) • Cadera (cm)
Composición corporal	<ul style="list-style-type: none"> • Báscula Tanita MC 780-P MA • Estadiómetro Seca 213 	<ul style="list-style-type: none"> • Grasa por extremidad y tronco (%) • Músculo por extremidad y tronco (%) • Grasa total y músculo (%) • Área de grasa visceral (cm²) • Peso (kg) • Altura (m)
Otro, Estilo de vida	Entrevista	<ul style="list-style-type: none"> • Actividad (puntuación) • Género • Edad (años)
Sangre (capilar)	Accutrend Plus	<ul style="list-style-type: none"> • Glucosa (mg/dL) • Colesterol (mg/dL) • Triglicéridos (mg/dL)
Presión arterial	Omron M3	<ul style="list-style-type: none"> • Presión sistólica (mmHg) • Presión diastólica (mmHg)

N. García-D'urso, P. Climent-Pérez, M. Sánchez-Sansegundo, A. Zaragoza-Martí, A. Fuster-Guilló and J. Azorín-López,

“A Non-Invasive Approach for Total Cholesterol Level Prediction Using Machine Learning,”


in *IEEE Access*, vol. 10, pp. 58566-58577, 2022, doi: [10.1109/ACCESS.2022.3178419](https://doi.org/10.1109/ACCESS.2022.3178419).

Limpieza de datos

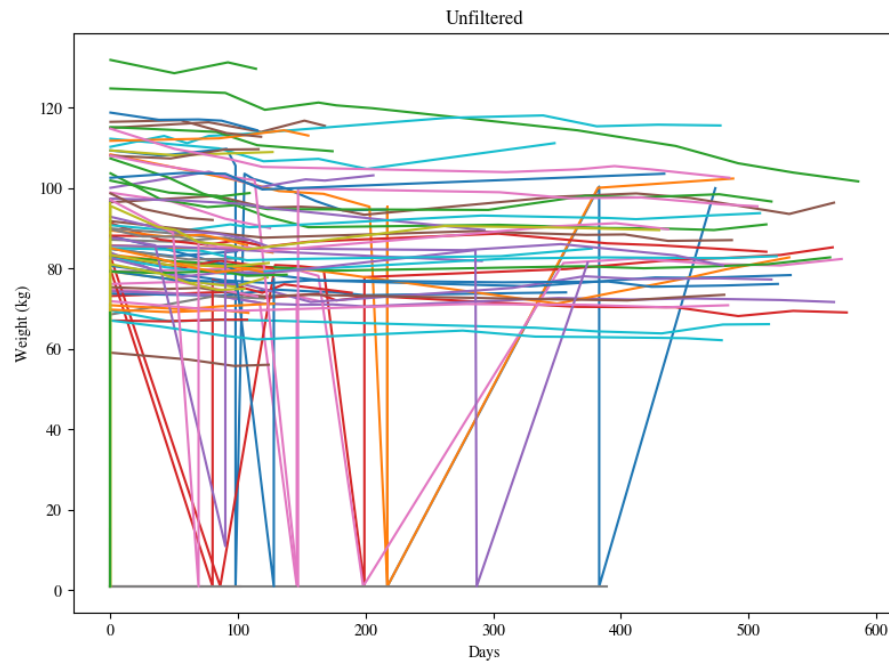
Creación de proceso de análisis y limpieza de datos usando la biblioteca *pandas*.

- Detección de casos atípicos.
 - Suma de músculo y grasa > 100 %.
 - Diferencias grandes entre medidas de extremidades.
- Errores decimales.
 - Omisión de separador decimal o unidades erróneas.


Filtrado de la variable “peso”



Filtrado de la variable “peso”




Sin filtrar



Filtrado

Sistema escaneo 3D

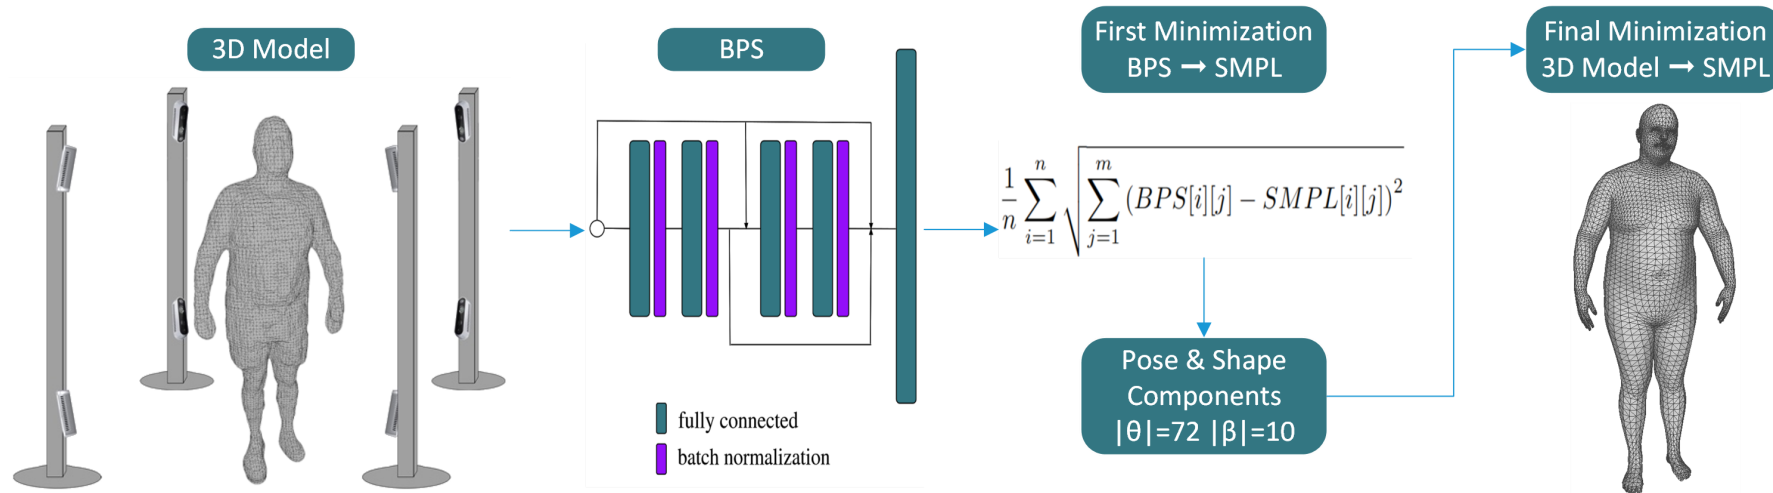


13 cámaras *Intel Realsense RGB-D*.

Extracción de parámetros *SMPL*

N. García-D'Urso et al., "Accurate estimation of parametric models of the human body from 3d point clouds"

Extracción de parámetros *SMPL*



1. Adquisición de modelos 3D.

- Capturar una nube de puntos con las 13 cámaras RGB-D.
- Reducir ruido y optimizar alineamiento

2. Estimación de plantilla intermedia con *BPS*.

- Codificar la nube de puntos usando *Basis Point Set*.
- Predecir posiciones de vértices con una *NN*.

3. Primera minimización.

- Minimizar parámetros *SMPL* para alinearlos con la plantilla creada con *BPS*.

4. Segunda minimización.

- Alinear modelo *SMPL* con el escaneo original.

Red neuronal

Análisis de arquitecturas para secuencias

Tipos planteados:

- Recurrentes
 - RNN
 - LSTM
 - GRU
- Transformers

Problemas

Pacientes con distinto número de sesiones.

Pacientes con sesiones espaciadas irregularmente o faltantes.

Problemas

Pacientes con distinto número de sesiones.

Las redes recurrentes son flexibles respecto a la longitud de secuencia.

Pacientes con sesiones espaciadas irregularmente o faltantes.

Problemas

Pacientes con distinto número de sesiones.

Las redes recurrentes son flexibles respecto a la longitud de secuencia.

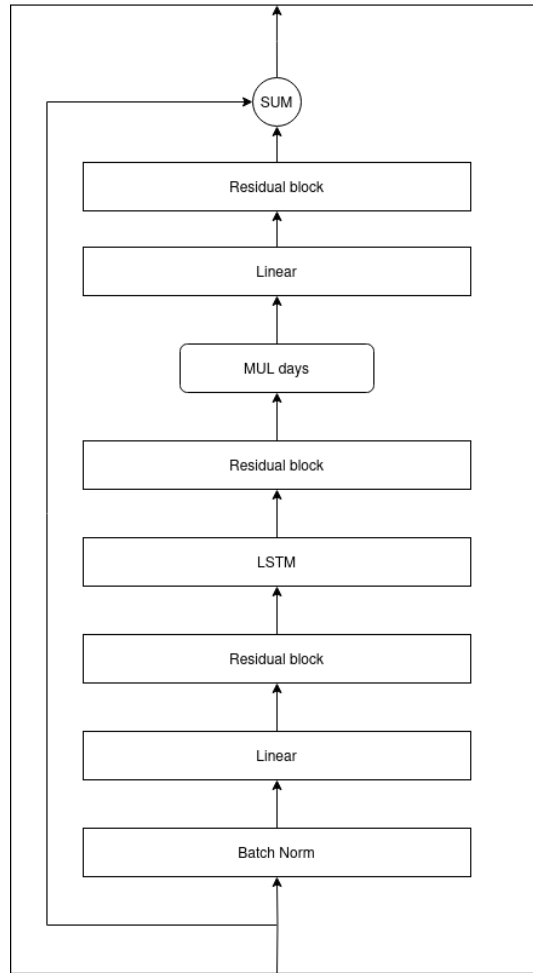
Pacientes con sesiones espaciadas irregularmente o faltantes.

En vez de predecir la siguiente sesión, predecir el cambio diario.

Detalles de la arquitectura

Añadimos una conexión residual para calcular la variación entre sesiones.

Calculamos los días entre sesiones y multiplicamos las predicciones por ese valor.




$$X : ([B, [T_1, \dots, T_{N_{max}-1}], [\beta, Height, Weight, Age, Sex]], Days)$$
$$Y : [B, [T_2, \dots, T_{N_{max}}], [\beta, Height, Weight, Age, Sex]]$$

Desarrollamos la red neuronal utilizando la biblioteca *PyTorch* con aceleración por *GPU*.


Implementamos una búsqueda de malla de hiperparámetros.

Entrenamos usando un *learning rate* dinámico y el optimizador *AdamW*, con validación *5-fold*.




Hiper-parámetro	Valor
Tamaño del lote (<i>Batch size</i>)	32
Número de capas en la entrada	4
Número de capas en el LSTM	4
Número de capas en la salida	4
Tamaño oculto (H)	32
Decaimiento de peso (<i>Weight decay</i>)	0.001


Resultados



Error medio por parámetro β .



Predicciones de parámetros β .



Ground truth y predicciones de un paciente.

Discusión

- Escala de tiempo pequeña para aprender dinámicas a largo plazo.
- Error alto en el *ground truth*.

Posibles futuras líneas de trabajo

- **Recolección de Datos:** Los pacientes podrían enviar imágenes en lugar de escaneos 3D *in-situ* para tener más datos.
- **Arquitectura de Red Neuronal:** Aunque elegimos la arquitectura *LSTM*, se podrían explorar otras, como Transformers, buscando mejoras en el rendimiento de predicción.
- **Modelos Paramétricos:** Considerar otros modelos como *STAR* como alternativas o complementos al modelo *SMPL* utilizado.
- **Renderizado de Salida:** Explorar *SMPLpix* para renderizar en 2D. Usando el mismo modelo y parámetros predichos, podríamos generar imágenes realistas de los cuerpos en lugar de depender de modelos 3D.

Muchas gracias